

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



XỬ LÝ NGÔN NGỮ TỰ NHIÊN NÂNG CAO

**Xây dựng ngữ liệu đơn ngữ chữ Hán
chuyên ngành lịch sử Trung Quốc phong kiến
(Đề tài 35)**

Giảng viên hướng dẫn: PGS. TS. Đinh Điền

TS. Nguyễn Hồng Bửu Long

TS. Lương An Vinh

Học viên thực hiện: 24C11021 - Lê Minh Phục

24C11035 - Nguyễn Thế Vinh

25C15043 - Trần Ngọc Bảo

25C15062 - Nguyễn Đăng Thới Toàn

1 Giới thiệu

1.1 Mục tiêu của đề án

Đề án nhằm xây dựng quy trình xử lý ngữ liệu Hán cổ, chuyển đổi văn bản thô thành dữ liệu có cấu trúc phục vụ các bài toán xử lý ngôn ngữ tự nhiên. Quy trình gồm hai tác vụ chính: tách câu và nhận diện thực thể.

1.2 Bài toán được giao

Tác vụ thứ nhất là tách văn bản Hán cổ từ file `.txt` thành các câu riêng biệt. Mỗi câu được gán một mã định danh duy nhất, với chỉ số câu trong mỗi cuốn được đánh số từ 0, và được lưu trong file `.tsv`.

Tác vụ thứ hai là nhận diện thực thể trên các câu đã được tách. Các thực thể được phân thành sáu nhãn: PER, LOC, ORG, TITLE, TME và NUM. Kết quả được lưu dưới định dạng `.json`.

Quy trình tổng quát:

TXT $\rightarrow$ Tách câu $\rightarrow$ TSV $\rightarrow$ NER $\rightarrow$ JSON

1.3 Phạm vi dữ liệu và kết quả mong đợi

Phạm vi dữ liệu của đề án gồm tám bộ sử liệu thuộc **đề tài 35**, được ký hiệu từ HCH_009 đến HCH_016:

- HCH_009: Kim Sử.
- HCH_010: Liêu Sử.
- HCH_011: Lương Thư.
- HCH_012: Minh Sử.
- HCH_013: Minh Sử Kỷ Sự Bản Mạt.
- HCH_014: Mục Thiên Tử Truyện.
- HCH_015: Nam Tề Thư.
- HCH_016: Ngô Việt Xuân Thu.

Kết quả mong đợi gồm các file `.tsv` chứa các câu đã được tách và các file `.json` chứa kết quả nhận diện thực thể tương ứng. Dữ liệu đầu ra cần bảo đảm đúng định dạng, đúng cấu trúc thư mục và nhất quán giữa hai loại file.

2 Dữ liệu và công cụ sử dụng

2.1 Mô tả dữ liệu đầu vào

Dữ liệu đầu vào gồm tám văn bản Hán cổ, được mã hóa từ HCH_009 đến HCH_016. Mỗi tác phẩm ban đầu được lưu dưới dạng file văn bản `.txt`.

Đối với tác vụ tách câu, hệ thống nhận file `.txt`, tách văn bản theo từng quyển hoặc đơn vị nội dung và tạo các file `.tsv`. Mỗi dòng trong file TSV gồm mã câu `sentence_id` và nội dung `sentence`.

Đối với tác vụ nhận diện thực thể, các file `.tsv` được sử dụng làm đầu vào. Kết quả được lưu dưới dạng `.json`, trong đó mỗi câu chứa danh sách thực thể và nhãn tương ứng gồm PER, LOC, ORG, TITLE, TME và NUM.

2.2 Nguồn dữ liệu

Nguồn dữ liệu là các văn bản Hán cổ được cung cấp cho đề án, gồm Kim Sử, Liêu Sử, Lương Thư, Minh Sử, Minh Sử Kỷ Sự Bản Mạt, Mục Thiên Tử Truyện, Nam Tề Thư và Ngô Việt Xuân Thu.

2.3 Công cụ, thư viện và mô hình

Cả hai tác vụ được triển khai bằng ngôn ngữ Python.

Tác vụ tách câu sử dụng phương pháp dựa trên luật, kết hợp biểu thức chính quy để xác định tiêu đề, quyển và ranh giới câu. Hai script chính là `segment_han_rule.py` và `segment_han_by_volume.py`. Các thư viện hỗ trợ gồm `regex`, `pandas`, `tqdm` và `openpyxl`.

Tác vụ nhận diện thực thể sử dụng mô hình Qwen3-30B-A3B-GPTQ-Int4, được suy luận cục bộ bằng vLLM trên GPU NVIDIA GeForce RTX 5090. Ngoài ra, các thư viện `json`, `argparse`, `pathlib` và `re` được sử dụng để đọc dữ liệu, xây dựng prompt, kiểm tra định dạng và hậu xử lý kết quả.

3 Quy trình thực hiện

3.1 Mô tả tổng quan quy trình

Quy trình xử lý dữ liệu gồm hai tác vụ liên tiếp: tách câu và nhận diện thực thể. Dữ liệu được chuyển đổi theo chuỗi sau:

$$\text{TXT} \rightarrow \text{Tách câu} \rightarrow \text{TSV} \rightarrow \text{NER} \rightarrow \text{JSON}$$

Ở tác vụ thứ nhất, văn bản Hán cổ được chia theo từng quyển, tách thành các câu riêng biệt, gán mã định danh và lưu dưới định dạng `.tsv`. Ở tác vụ thứ hai, các câu đã được tách được đưa vào mô hình để nhận diện và gán nhãn thực thể.

3.2 Các bước thực hiện chính

3.2.1 Tách câu

Quy trình tách câu được thực hiện theo từng tác phẩm và từng quyển. Trước hết, chương trình đọc nội dung từ file `.txt`, chuẩn hóa ký tự xuống dòng, khoảng trắng và một số ký tự đặc biệt nhưng không làm thay đổi nội dung Hán cổ.

Tiếp theo, văn bản được chia thành các đơn vị nhỏ hơn dựa trên tiêu đề quyển có dạng `# 卷...`. Riêng tác phẩm `HCH_016` không được đánh số theo quyển trong dữ liệu nguồn mà được tổ chức thành các phần nội dung riêng theo từng tiêu đề; do đó, chương trình sử dụng các tiêu đề này để xác định ranh giới giữa các đơn vị.

Trước khi tách câu, các dòng không thuộc nội dung sử liệu được loại bỏ, gồm:

- Tiêu đề quyển, tên chương và mục lục.
- Liên kết dự án, siêu dữ liệu và thông tin bản quyền.
- Ghi chú hiệu đính, chú thích và một số danh sách chức quan ở phần phụ lục.
- Các dòng trống hoặc dòng quá ngắn không có đặc điểm của một câu hoàn chỉnh.

Nội dung còn lại được làm sạch bằng cách loại bỏ ký hiệu đầu dòng, dấu tham chiếu chú thích và khoảng trắng không cần thiết. Một số lỗi dấu ngoặc kép phổ biến trong dữ liệu nguồn cũng được chuẩn hóa trước khi tách câu.

Ranh giới câu chủ yếu được xác định theo ba dấu kết thúc câu `。`, `！` và `？`. Dấu `；` không được xem là ranh giới câu chính vì trong sử liệu, dấu này thường dùng để phân cách các thành phần liệt kê hoặc các mệnh đề liên quan.

Chương trình đồng thời xử lý các trường hợp dấu câu xuất hiện bên trong dấu trích dẫn 「」 hoặc 『』. Khi dấu kết thúc câu nằm trong lời dẫn, câu chỉ được tách sau dấu đóng ngoặc để tránh Xử Lý Ngôn Ngữ Tự Nhiên Nâng Cao

làm vỡ nội dung trích dẫn. Một số dấu hiệu đặc trưng như 贊曰: hoặc biểu thức thời gian xuất hiện ngay sau phần trích dẫn cũng được dùng để xác định ranh giới câu mới.

Đối với các trường hợp dấu ngoặc bị thiếu hoặc câu quá dài, chương trình sử dụng giới hạn độ dài để tránh nhiều câu bị ghép thành một câu duy nhất. Việc tách bổ sung theo các dấu , , \ , : và ; chỉ được sử dụng khi cần thiết.

Sau cùng, các câu có độ dài hợp lệ được gán mã `sentence_id` duy nhất, với chỉ số bắt đầu từ 0 trong mỗi quyển, rồi lưu vào file `_seg.tsv`. Mỗi dòng gồm hai trường:

`sentence_id` và `sentence`

Sau khi tách câu, nhóm kiểm tra lại nội dung và cấu trúc đầu ra để phát hiện các lỗi như mất ký tự, sai ranh giới câu, đưa nhầm tiêu đề vào ngữ liệu, trùng mã câu hoặc sai thứ tự `sentence_id`.

3.2.2 Khảo sát các phương pháp nhận diện thực thể

Trước khi lựa chọn phương pháp chính thức, nhóm đã thử nghiệm nhiều hướng tiếp cận khác nhau cho bài toán nhận diện thực thể trên sử liệu Hán cổ.

Sử dụng mô hình Qwen thông qua API. Nhóm thử nghiệm gọi mô hình Qwen thông qua một số dịch vụ đám mây như Groq và Alibaba Cloud. Phương pháp này không yêu cầu cài đặt mô hình trên máy cục bộ và thuận tiện cho việc thử nghiệm nhanh.

Tuy nhiên, số lượng token miễn phí bị giới hạn, thời gian suy luận tương đối lâu khi xử lý số lượng lớn câu và việc gọi API liên tục có thể bị giới hạn tốc độ. Do đó, phương pháp này chỉ được sử dụng để thử nghiệm trên một phần nhỏ dữ liệu, không phù hợp để xử lý toàn bộ ngữ liệu.

Sử dụng HanLP. Nhóm thử nghiệm các mô hình nhận diện thực thể có sẵn trong HanLP. HanLP hỗ trợ nhiều tác vụ xử lý tiếng Trung, tuy nhiên các mô hình chủ yếu được huấn luyện trên tiếng Trung hiện đại.

Khi áp dụng trực tiếp cho sử liệu Hán cổ, kết quả nhận diện chưa đạt yêu cầu. Mô hình thường bỏ sót hoặc nhận diện sai tên người, địa danh, chức danh và biểu thức thời gian. Nguyên nhân chính là sự khác biệt về từ vựng, ngữ pháp và cách biểu đạt giữa tiếng Trung hiện đại và văn bản Hán cổ.

Fine-tune GujiRoBERTa. Nhóm cũng thử nghiệm fine-tune mô hình GujiRoBERTa_jian_fan, một mô hình tiền huấn luyện dành cho văn bản cổ. Dữ liệu EvaHan 2025 được sử dụng làm dữ liệu huấn luyện cho tác vụ nhận diện thực thể.

Do hệ thống nhãn của EvaHan 2025 không hoàn toàn giống với yêu cầu của đề án, nhóm xây dựng quy tắc ánh xạ các nhãn từ dữ liệu huấn luyện sang sáu nhãn PER, LOC, ORG, TITLE, TME và NUM.

Phương pháp này có ưu điểm là sử dụng mô hình chuyên biệt cho văn bản cổ. Tuy nhiên, kết quả còn phụ thuộc vào sự khác biệt giữa dữ liệu EvaHan 2025 và các bộ dữ liệu trong đồ án. Một số nhãn không có quan hệ ánh xạ trực tiếp, dẫn đến hiện tượng mất thông tin hoặc gán nhãn chưa chính xác.

Suy luận Qwen bằng vLLM trên máy cục bộ. Phương pháp cuối cùng được nhóm thử nghiệm là triển khai mô hình Qwen trên máy cục bộ và sử dụng thư viện vLLM để thực hiện suy luận.

Nhóm xây dựng prompt mô tả ý nghĩa của từng nhãn, quy tắc nhận diện, định dạng JSON đầu ra và các ví dụ trong văn bản Hán cổ. Để tăng khả năng nhận diện, một số câu đứng trước và sau câu mục tiêu được bổ sung làm ngữ cảnh.

Việc triển khai cục bộ giúp nhóm chủ động kiểm soát mô hình, prompt, kích thước batch và các tham số suy luận. Phương pháp này không bị giới hạn bởi token miễn phí, có thể xử lý toàn bộ dữ liệu và cho kết quả ổn định hơn so với các phương pháp đã thử nghiệm.

Sau khi so sánh, nhóm lựa chọn Qwen chạy cục bộ bằng vLLM làm phương pháp chính để tạo kết quả NER.

3.2.3 Quy trình nhận diện thực thể bằng Qwen và vLLM

Quy trình nhận diện thực thể chính thức gồm các bước sau:

1. Đọc nội dung câu và mã câu từ các file `_seg.tsv`.
2. Bổ sung một số câu trước và sau để cung cấp ngữ cảnh cho câu cần xử lý.
3. Xây dựng prompt mô tả sáu nhãn thực thể và định dạng đầu ra yêu cầu.
4. Gom nhiều câu thành batch và thực hiện suy luận bằng mô hình Qwen3 thông qua vLLM.
5. Phân tích kết quả mô hình sinh ra và chuyển về cấu trúc JSON thống nhất.
6. Loại bỏ các nhãn không hợp lệ, thực thể không xuất hiện trong câu và các kết quả trùng lặp.
7. Khôi phục một số thực thể thời gian hoặc số lượng bị bỏ sót bằng các quy tắc hậu xử lý.
8. Lưu kết quả thành file `_ner.json` tương ứng với từng file `_seg.tsv`.

Kết quả được kiểm tra trên một số quyển đại diện. Các lỗi thường gặp được tổng hợp để điều chỉnh prompt và quy tắc hậu xử lý trước khi áp dụng cho toàn bộ dữ liệu.

4 Kết quả đạt được

4.1 Khối lượng dữ liệu xử lý

Nhóm đã hoàn thành toàn bộ dữ liệu được phân công, gồm tám bộ sử liệu từ HCH_009 đến HCH_016. Tổng cộng có 795 quyển hoặc đơn vị nội dung được tổ chức trong thư mục đầu ra.

Trong đó, 789 quyển có nội dung sử liệu và đã được xử lý qua hai tác vụ:

- Tách văn bản từ file `.txt` thành các câu và lưu trong file `_seg.tsv`.
- Nhận diện thực thể trên các câu đã tách và lưu kết quả trong file `_ner.json`.

Tổng số câu thu được là 270.814 câu. Số lượng câu trong các file `_seg.tsv` và số lượng bản ghi trong các file `_ner.json` tương ứng bằng nhau.

Có sáu quyển không chứa nội dung sử liệu hợp lệ để tách câu và nhận diện thực thể, gồm HCH_009_061, HCH_009_062, HCH_012_101, HCH_012_102, HCH_012_110 và HCH_012_112. Nội dung nguồn của các quyển này chỉ gồm liên kết dự án, thông tin bản quyền hoặc siêu dữ liệu nên không được đưa vào ngữ liệu.

4.2 Các sản phẩm đầu ra đã tạo

Đối với tác vụ tách câu, nhóm đã tạo các file `_seg.tsv`. Mỗi dòng gồm hai trường:

`sentence_id` và `sentence`

Chỉ số câu trong mỗi quyển được đánh số bắt đầu từ 0. Ví dụ:

HCH_009_001_000000

Đối với tác vụ nhận diện thực thể, nhóm đã tạo các file `_ner.json`. Mỗi phần tử gồm mã câu, nội dung câu và danh sách thực thể thuộc một trong sáu nhãn: PER, LOC, ORG, TITLE, TME và NUM.

Các câu không chứa thực thể vẫn được giữ lại với danh sách `entities` rỗng. Toàn bộ kết quả được tổ chức theo từng tác phẩm và từng quyển, đúng quy tắc đặt tên và cấu trúc thư mục được yêu cầu. Mã câu, thứ tự câu và nội dung câu giữa file `_seg.tsv` và file `_ner.json` tương ứng được bảo đảm nhất quán.

5 Đánh giá và thảo luận

5.1 Cách đánh giá kết quả

Kết quả được đánh giá bằng hai hình thức: kiểm tra tự động trên toàn bộ dữ liệu và kiểm tra thủ công trên một số quyền đại diện thuộc các bộ dữ liệu từ HCH_009 đến HCH_016.

Đối với tác vụ tách câu, các tiêu chí đánh giá gồm:

- Ranh giới câu có phù hợp với dấu câu và nội dung văn bản hay không.
- Nội dung câu có được giữ nguyên so với văn bản nguồn hay không.
- Có xuất hiện trường hợp tách sai hoặc ghép nhiều câu thành một câu hay không.
- Mã `sentence_id` có đúng định dạng, đúng thứ tự và không bị trùng lặp hay không.

Đối với tác vụ nhận diện thực thể, kết quả được đối chiếu với nội dung câu và ngữ cảnh xung quanh. Các lỗi chính được xem xét gồm bỏ sót thực thể, nhận diện thừa, gán sai nhãn và xác định sai phạm vi thực thể.

Ngoài ra, toàn bộ dữ liệu đầu ra được kiểm tra về cấu trúc thư mục, tên file, số lượng câu và sự nhất quán giữa file `_seg.tsv` và file `_ner.json` tương ứng.

5.2 Kết quả đánh giá

Kết quả tách câu nhìn chung giữ được nội dung văn bản và đáp ứng đúng định dạng TSV. Phần lớn câu được tách theo dấu câu có sẵn trong nguồn dữ liệu. Một số trường hợp đặc biệt như tiêu đề quyền, thông tin bản quyền hoặc siêu dữ liệu đã được loại bỏ khỏi ngữ liệu.

Đối với tác vụ nhận diện thực thể, kết quả kiểm tra mẫu cho thấy mô hình có khả năng nhận diện tương đối phù hợp với các thực thể phổ biến như tên người, biểu thức thời gian và số lượng. Tuy nhiên, các nhãn `LOC`, `ORG` và `TITLE` vẫn có thể bị nhầm lẫn trong những câu thiếu ngữ cảnh hoặc có cách diễn đạt đặc thù.

Về mặt định dạng, dữ liệu đầu ra bảo đảm đúng cấu trúc yêu cầu. Mã câu, nội dung câu và số lượng bản ghi giữa các file tách câu và NER tương ứng được kiểm tra để bảo đảm tính nhất quán.

5.3 Những vấn đề gặp phải

Một số vấn đề chính trong quá trình thực hiện gồm:

- Dấu câu và cách tổ chức nội dung giữa các bộ dữ liệu không hoàn toàn thống nhất.
- Tiêu đề quyền, tên chương, liên kết hoặc thông tin bản quyền có thể bị nhận nhầm là nội dung sử dụng.

- Một số câu dài và chứa nhiều mệnh đề gây khó khăn cho việc xác định ranh giới câu.
- Một tên gọi có thể được hiểu là địa danh, tổ chức, bộ tộc hoặc triều đại tùy theo ngữ cảnh.
- Chức tước đôi khi được dùng thay cho tên người.
- Mô hình có thể bỏ sót biểu thức thời gian, số lượng hoặc sinh kết quả chưa đúng định dạng.
- Quy tắc hậu xử lý phù hợp với bộ dữ liệu này nhưng có thể chưa phù hợp hoàn toàn với bộ dữ liệu khác.

5.4 Phân tích nguyên nhân

Các lỗi tách câu chủ yếu xuất phát từ sự khác biệt về dấu câu, tiêu đề và cấu trúc văn bản giữa các nguồn. Một số văn bản còn chứa nội dung ngoài ngữ liệu như liên kết, ghi chú hoặc thông tin bản quyền, do đó cần được nhận diện và loại bỏ trước khi xử lý.

Đối với NER, văn bản Hán cổ có cách dùng từ và cấu trúc khác với tiếng Trung hiện đại. Nhiều thực thể chỉ có thể xác định chính xác khi kết hợp ngữ cảnh và kiến thức lịch sử. Bên cạnh đó, mô hình chưa được huấn luyện chuyên biệt trên toàn bộ các bộ dữ liệu của đề án, dẫn đến một số trường hợp bỏ sót hoặc gán nhãn chưa chính xác.

6 Kết luận và hướng phát triển

6.1 Những nội dung đã hoàn thành

Đồ án đã xây dựng quy trình $\text{TXT} \rightarrow \text{Tách câu} \rightarrow \text{TSV} \rightarrow \text{NER} \rightarrow \text{JSON}$ cho ngữ liệu Hán cổ, với các kết quả chính:

- Chuyển đổi văn bản `.txt` thành các câu trong file `.tsv`, tổ chức theo từng tác phẩm, quyển hoặc đơn vị nội dung và gán `sentence_id` bắt đầu từ 0.
- Nhận diện sáu loại thực thể gồm `PER`, `LOC`, `ORG`, `TITLE`, `TME` và `NUM`.
- Khảo sát nhiều phương pháp NER và lựa chọn Qwen chạy cục bộ bằng `vLLM`.
- Chuẩn hóa kết quả sang `.json`, kiểm tra định dạng, số lượng câu và tính nhất quán giữa các file `_seg.tsv` và `_ner.json`.
- Kiểm tra thủ công một số quyển đại diện để phát hiện và điều chỉnh các lỗi phổ biến.

6.2 Những hạn chế còn tồn tại

- Quy tắc tách câu chưa xử lý hoàn toàn chính xác mọi cấu trúc đặc biệt và một số trường hợp vẫn cần điều chỉnh thủ công.
- Chưa có tập dữ liệu chuẩn đầy đủ để đánh giá định lượng trên toàn bộ ngữ liệu.
- Các nhãn `LOC`, `ORG` và `TITLE` còn có thể bị nhầm lẫn trong những trường hợp phụ thuộc nhiều vào ngữ cảnh.
- Mô hình đôi khi bỏ sót thực thể, gán sai nhãn hoặc xác định chưa chính xác phạm vi thực thể.
- Các quy tắc hậu xử lý chưa thể áp dụng đồng nhất cho mọi bộ sử liệu.

Trong tương lai, hệ thống có thể được cải thiện bằng cách xây dựng tập dữ liệu chuẩn, bổ sung từ điển tên người, địa danh và chức tước lịch sử, đồng thời tinh chỉnh mô hình trên ngữ liệu Hán cổ chuyên biệt.